RAG Multimodal: Recuperación y Fusión Cross-Modal de Texto, Imagen, Audio y Tablas

Damy Villegas - Sara Diaz -, Daniel Guzman
1081274572@correo.icesi.edu.co - sara.diaz@u.icesi.edu.co - jose.guzmancastrillon@u.icesi.edu.co

***Resumen*—** La Generación Aumentada por Recuperación (RAG) ha probado ser un enfoque eficaz para reducir las alucinaciones y la desactualización del conocimiento de los grandes modelos de lenguaje. Sin embargo, el conocimiento del mundo real rara vez existe en un único formato: imágenes, video, audio y tablas conviven con el texto y con frecuencia contienen la evidencia más relevante para responder una consulta. Este artículo presenta una revisión del estado del arte del RAG Multimodal, tomando como referencia principal el trabajo de Abootorabi et al. (2025) y su repositorio asociado. Se describe el pipeline general de un sistema de RAG multimodal —recuperación, fusión, aumento y generación— y se organiza la literatura reciente en una taxonomía que cubre estrategias de recuperación eficiente, codificadores multimodales, recuperación centrada en modalidad, mecanismos de reordenamiento, fusión por score y por atención, técnicas de aumento del contexto y estrategias de generación (aprendizaje en contexto, razonamiento y atribución de fuentes). Asimismo, se documentan los conjuntos de datos y las métricas de evaluación más utilizados. Los hallazgos muestran que, pese al rápido avance de esta área, la alineación semántica entre modalidades heterogéneas —con distintas granularidades temporales y espaciales— sigue siendo un reto abierto que limita la robustez de estos sistemas. Se concluye que el RAG multimodal constituye una frontera de investigación activa y poco saturada, con oportunidades claras en evaluación estandarizada, arquitecturas de fusión más eficientes y enfoques basados en agentes.

***Índice de Términos*—** alineación cross-modal, fusión multimodal, recuperación de información, RAG multimodal.

I. Introducción

Los grandes modelos de lenguaje (LLM) han demostrado capacidades notables de generación de texto, pero su conocimiento queda fijo en el momento del entrenamiento y son propensos a producir alucinaciones, es decir, afirmaciones que suenan plausibles pero son incorrectas [2]. La Generación Aumentada por Recuperación (Retrieval-Augmented Generation, RAG) mitiga este problema complementando al modelo con evidencia recuperada de una base de conocimiento externa y actualizable, lo que mejora el anclaje factual de sus respuestas [2].

Sin embargo, buena parte del conocimiento relevante para responder una consulta no está almacenado únicamente en texto: un informe médico puede depender de una radiografía, un manual técnico de una tabla de especificaciones, y una consulta sobre un evento de una grabación de audio o un video. El RAG Multimodal extiende el paradigma de RAG incorporando texto, imagen, audio, video y tablas tanto en la etapa de recuperación como en la de generación, con el fin de producir respuestas mejor fundamentadas y más completas [1].

No obstante, combinar modalidades heterogéneas introduce dificultades que no existen en el RAG unimodal: cada modalidad posee su propia granularidad, ruido y espacio de representación, por lo que alinear semánticamente contenido de distinta naturaleza —y razonar conjuntamente sobre él— constituye un reto abierto [1]. Este trabajo toma como referencia principal la revisión de Abootorabi et al. (2025), “Ask in Any Modality: A Comprehensive Survey on Multimodal Retrieval-Augmented Generation” [1], y su repositorio de código y bibliografía asociado, para presentar una síntesis organizada del estado del arte, con énfasis particular en los problemas de alineación y fusión cross-modal.

El resto del artículo se organiza así: la Sección II describe el marco teórico del RAG multimodal y la metodología seguida en esta revisión; la Sección III presenta los resultados, organizados como una taxonomía de estrategias de recuperación, fusión, aumento y generación, junto con los conjuntos de datos y métricas más

usados; la Sección IV discute los retos abiertos, en particular la alineación cross-modal; y la Sección V concluye el trabajo.

II. Materiales y Métodos

A. Marco teórico

En su forma original, un sistema RAG combina un recuperador (retriever) y un generador (generator) [2]. Dada una consulta, el recuperador la codifica como un vector y busca, por similitud, los elementos más relevantes en una base de conocimiento externa; estos elementos se concatenan o inyectan en el prompt del generador, típicamente un LLM, que produce la respuesta final apoyándose en dicha evidencia.

En el caso multimodal, la base de conocimiento contiene elementos de distintas modalidades (texto, imagen, audio, video, tablas), y tanto la consulta como los documentos pueden pertenecer a cualquiera de ellas. Para permitir la recuperación cross-modal —por ejemplo, responder una pregunta en texto recuperando una imagen— se emplean codificadores multimodales que proyectan cada modalidad a un espacio de representación común o alineado, como en los modelos de tipo CLIP o BLIP [3], [4]. A partir de dicha representación, el proceso general de un sistema de RAG multimodal puede describirse en cuatro etapas —recuperación, fusión, aumento y generación—, tal como se ilustra en la Fig. 1, siguiendo la organización propuesta en el trabajo base

[1].

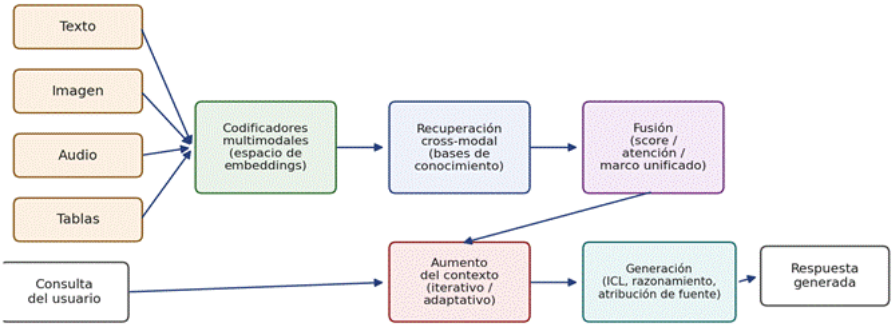


Fig. 1. Pipeline general de un sistema de RAG multimodal: recuperación, fusión, aumento y generación a partir de evidencia en texto, imagen, audio y tablas (adaptado de la taxonomía de [1]).

B. Metodología de la revisión

Esta investigación es de tipo documental y no involucra experimentación propia. La fuente primaria fue el artículo de Abootorabi et al. (2025) [1] (arXiv:2502.08826, DOI: 10.48550/arXiv.2502.08826), aceptado en ACL 2025 Findings, junto con su repositorio público en GitHub (llm-lab-org/Multimodal-RAG-Survey), que organiza y mantiene actualizada una bibliografía de más de un centenar de trabajos clasificados según la taxonomía del survey.

El proceso de revisión siguió tres pasos: (i) lectura completa del artículo base para identificar su taxonomía y sus principales hallazgos; (ii) exploración del repositorio asociado, categoría por categoría, para seleccionar los trabajos más representativos de cada rama (recuperación, fusión, aumento, generación, entrenamiento y robustez); y (iii) consulta puntual de los artículos originales referenciados por el survey, con el fin de contextualizar y verificar las afirmaciones incluidas en este documento. Los criterios de inclusión priorizaron trabajos citados por el survey base que ejemplifican claramente cada categoría de la taxonomía, así como aquellos que discuten explícitamente el problema

III. Resultados

A. Estrategias de recuperación

La Tabla I resume la taxonomía de estrategias de recuperación identificada en la literatura [1]. Un primer grupo corresponde a la búsqueda eficiente por similitud, que incluye técnicas de Maximum Inner Product Search

(MIPS) para escalar la búsqueda vectorial y codificadores multimodales que proyectan distintas modalidades a un espacio compartido, como CLIP [3] y BLIP [4]. Un segundo grupo agrupa la recuperación centrada en una modalidad específica: texto, visión (p. ej., ColPali [8]), video, audio y documentos con diseño de página complejo, donde destacan enfoques que tratan la página completa como imagen, como DSE [10] o M3DocRAG [9]. Un tercer grupo corresponde a estrategias de reordenamiento (re-ranking) posteriores a la recuperación inicial, mediante selección de ejemplos, evaluación de puntajes de relevancia o mecanismos de filtrado, que buscan mejorar la precisión del conjunto final de evidencia.

TABLA I

TAXONOMÍA DE ESTRATEGIAS DE RECUPERACIÓN

Categoría	Subcategorías	Ejemplos representativos
Búsqueda eficiente y similitud	Maximum Inner Product Search (MIPS); codificadores multimodales	CLIP [3], BLIP [4]
Recuperación centrada en modalidad	Texto; visión; video; audio; documentos y diseño de página	ColPali [8], DSE [10], M3DocRAG [9]
Reordenamiento (re-ranking)	Selección de ejemplos; evaluación de relevancia; filtrado	—

B. Fusión y aumento del contexto

La fusión es la etapa donde la evidencia multimodal recuperada se combina antes o durante la generación (Tabla II). Se distinguen mecanismos de fusión por score o alineación, que combinan puntuaciones de similitud de distintas modalidades, como en VisRAG [7] o MuRAG [6]; mecanismos basados en atención, que ponderan dinámicamente la evidencia relevante; y marcos unificados que integran recuperación y generación en una sola arquitectura entrenable conjuntamente. En paralelo, las técnicas de aumento del contexto enriquecen la consulta o el prompt con la evidencia recuperada de forma adaptativa e iterativa, permitiendo, por ejemplo, refinar la consulta o recuperar nuevamente si la evidencia inicial resulta insuficiente [1].

C. Generación

Sobre la evidencia recuperada y fusionada, la etapa de generación emplea aprendizaje en contexto (in-context learning) para condicionar al modelo generativo, técnicas de razonamiento explícito que encadenan pasos intermedios antes de responder, ajuste por instrucciones (instruction tuning) específico para tareas de RAG multimodal, y mecanismos de atribución de fuente y transparencia de evidencia, como VISA [11], que vinculan cada afirmación generada con la región visual o el documento del que proviene, favoreciendo la verificabilidad de la respuesta.

TABLA II

MECANISMOS DE FUSIÓN Y GENERACIÓN

Categoría	Descripción	Ejemplos
Fusión por score / alineación	Combina puntuaciones de similitud entre modalidades	VisRAG [7], MuRAG [6]
Fusión por atención	Pondera dinámicamente la evidencia relevante durante la generación	—
Marcos unificados	Entrenan conjuntamente recuperación y generación	—

Generación	Aprendizaje en contexto, razonamiento, ajuste por instrucciones y atribución de fuente	VISA [11]

D. Conjuntos de datos y métricas de evaluación

La Tabla III resume conjuntos de datos representativos por modalidad, utilizados para entrenar y evaluar sistemas de RAG multimodal. En cuanto a evaluación, se combinan métricas heredadas de la generación de texto (BLEU, ROUGE, exactitud de respuesta) con métricas propias de recuperación (Recall@k, MRR) y métricas más recientes orientadas a factualidad y atribución de la evidencia, dado que una respuesta puede ser fluida y, aun así, estar mal fundamentada en la evidencia recuperada [1].

TABLA III

CONJUNTOS DE DATOS REPRESENTATIVOS POR MODALIDAD

Modalidad	Dataset	Descripción breve
Imagen-Texto	MS-COCO	Alrededor de 330K imágenes con descripciones en texto.
Imagen-Texto	LAION-5B	5 mil millones de pares imagen-texto usados como memoria externa de recuperación.
Video-Texto	MSR-VTT	10K videos con 20 descripciones cada uno.
Video-Texto	ActivityNet	20K videos con múltiples descripciones por video.
Audio-Texto	LibriSpeech	1000 horas de habla leída en inglés con su transcripción.
Audio-Texto	AudioCaps	46K clips de audio con descripciones escritas por humanos.
Médico	MIMIC-CXR	125,417 radiografías de tórax con sus reportes clínicos.
QA multimodal	VQA / OK-VQA / WebQA	Preguntas que requieren imagen y, en ocasiones, conocimiento externo.

IV. Discusión

El resultado más consistente de esta revisión es que, pese al rápido crecimiento de propuestas, la alineación cross-modal continúa siendo el reto central del RAG multimodal [1]. Cada modalidad se representa en un espacio de embeddings distinto, entrenado con objetivos y datos diferentes; incluso los modelos de alineación más utilizados presentan dificultades para relacionar entidades específicas entre modalidades cuando la correspondencia no es directa, como lo documentan estudios recientes centrados en modelos de visión y lenguaje [13]. Esta brecha semántica se agrava cuando se combinan más de dos modalidades simultáneamente —por ejemplo, texto, imagen y audio en un mismo sistema—, escenario todavía poco explorado frente a los casos imagen-texto o video-texto.

Un segundo reto es la heterogeneidad y el ruido de la evidencia recuperada: contenido irrelevante o contradictorio entre modalidades puede degradar la generación e incluso inducir alucinaciones, a pesar de contar con recuperación [1], [12]. Esto ha motivado líneas de trabajo en robustez y manejo de ruido, así como estrategias de entrenamiento y funciones de pérdida específicas para RAG multimodal, orientadas a que el modelo aprenda cuándo confiar y cuándo descartar la evidencia recuperada.

Además, la evaluación no está estandarizada: distintos trabajos emplean métricas y protocolos diferentes según la modalidad predominante, lo que dificulta comparar sistemas entre sí y limita la reproducibilidad de resultados. La falta de benchmarks que integren de forma nativa más de dos modalidades —incluyendo tablas, un formato frecuente en dominios como finanzas, ciencia o documentos administrativos— es una brecha señalada explícitamente por el survey base [1].

También pesa el costo computacional de operar codificadores multimodales de gran escala y mecanismos de fusión por atención sobre evidencia extensa (por ejemplo, video completo o documentos largos con múltiples páginas), lo que plantea compromisos entre calidad y eficiencia. Frente a estas limitaciones, empiezan a consolidarse enfoques basados en agentes, que descomponen la tarea en subpasos de recuperación, verificación y generación coordinados por un controlador, así como marcos unificados que entrenan conjuntamente recuperación y generación en lugar de tratarlos como módulos independientes [1].

Estos elementos explican por qué el RAG multimodal se describe como una frontera de investigación activa y poco saturada: el repositorio asociado al survey base ha incorporado nuevas categorías —como interacción basada en agentes y recuperación centrada en audio— en actualizaciones posteriores a su publicación inicial, lo que evidencia que la taxonomía del campo aún está en formación y que persisten más preguntas abiertas que soluciones consolidadas, en particular alrededor de la alineación entre modalidades.

V. Conclusiones

Este artículo presentó una revisión organizada del RAG multimodal a partir del trabajo de Abootorabi et al. (2025) [1], describiendo su pipeline general —recuperación, fusión, aumento y generación— y sintetizando la taxonomía de técnicas, conjuntos de datos y métricas asociadas a cada etapa.

El análisis muestra que, aunque el RAG multimodal ha heredado y adaptado con éxito ideas del RAG unimodal y de los modelos de visión y lenguaje, la alineación semántica entre modalidades heterogéneas sigue siendo su principal limitación, seguida de la falta de benchmarks estandarizados que integren más de dos modalidades y de mecanismos robustos frente a evidencia ruidosa o contradictoria.

Como trabajo futuro, se recomienda explorar espacios de representación verdaderamente unificados para texto, imagen, audio y tablas; diseñar benchmarks multimodales que combinen simultáneamente más de dos modalidades; y avanzar en arquitecturas basadas en agentes que coordinen de forma explícita la recuperación, la verificación y la generación. Dado el carácter documental de este trabajo, una línea natural de continuación sería la implementación y evaluación empírica de alguna de estas estrategias sobre un conjunto de datos multimodal existente.

APÉNDICE

El autor agradece la orientación brindada en el curso de Inteligencia Artificial II de la Maestría en Inteligencia Artificial Aplicada de la Universidad Icesi para el desarrollo de este trabajo.

REFERENCIAS

[1] M. M. Abootorabi, A. Zobeiri, M. Dehghani, M. Mohammadkhani, B. Mohammadi, O. Ghahroodi, M. Soleymani Baghshah, and E. Asgari, “Ask in any modality: A comprehensive survey on multimodal retrieval-augmented generation,” in Findings of the Association for Computational Linguistics: ACL 2025, Vienna, Austria, 2025, pp. 16776–16809.

[2] P. Lewis et al., “Retrieval-augmented generation for knowledge-intensive NLP tasks,” arXiv:2005.11401, 2020.

[3] A. Radford et al., “Learning transferable visual models from natural language supervision,” arXiv:2103.00020, 2021.

[4] J. Li, D. Li, C. Xiong, and S. Hoi, “BLIP: Bootstrapping language-image pre-training for unified vision-language understanding and generation,” arXiv:2201.12086, 2022.

[5] M. Yasunaga et al., “Retrieval-augmented multimodal language modeling,” in Proc. 40th Int. Conf. Machine Learning (ICML), 2023.

[6] W. Chen, H. Hu, X. Chen, P. Verga, and W. W. Cohen, “MuRAG: Multimodal retrieval-augmented generator for open question answering over images and text,” arXiv:2210.02928, 2022.

[7] S. Yu et al., “VisRAG: Vision-based retrieval-augmented generation on multi-modality documents,” arXiv:2410.10594, 2024.

[8] M. Faysse et al., “ColPali: Efficient document retrieval with vision language models,” arXiv:2407.01449, 2024.

[9] J. Ma et al., “M3DocRAG: Multimodal retrieval is what you need for multi-page multi-document understanding,” arXiv:2411.04952, 2024.

[10] X. Ma, S.-C. Lin, M. Li, W. Chen, and J. Lin, “Unifying multimodal retrieval via document screenshot embedding,” arXiv:2406.11251, 2024.

[11] S. Sun et al., “VISA: Retrieval augmented generation with visual source attribution,” arXiv:2412.14457, 2024.

[12] Z. Liu et al., “Hallucination of multimodal large language models: A survey,” arXiv:2404.18930, 2024.

[13] I. Alonso, A. Salaberria, G. Azkune, J. Barnes, and O. Lopez de Lacalle, “Vision-language models struggle to align entities across modalities,” arXiv:2503.03854, 2025.

[14] llm-lab-org, “Multimodal-RAG-Survey” [Online repository]. Available: https://github.com/llm-lab-org/Multimodal-RAG-Survey. Accessed: Sep. 26, 2026.