Inteligencia Artificial • 2026

RAG Multimodal

Recuperación y fusión cross-modal

Dammy Villegas, Daniel Guzman, Sara Díaz

Text-only RAG vs. Multimodal RAG

Marco Teórico

¿Por qué RAG multimodal?

El problema comienza antes de seleccionar el modelo generador.

LLM Estándar

Conocimiento paramétrico estático.

Riesgo de alucinaciones plausibles.

RAG Textual

Recupera evidencia externa actualizable.

Optimiza anclaje factual en texto.

RAG Multimodal

Incorpora tablas, imágenes y gráficos.

La clave reside en otra modalidad.

Marco Teórico

Del RAG tradicional al RAG multimodal

El cambio crítico no es solo el generador: es el espacio de evidencia recuperable.



Marco Teórico

Pipeline general del RAG multimodal

La arquitectura canónica se estructura en cuatro fases secuenciales.

01

Recuperación

¿Qué evidencia es relevante en cada modalidad?

02

Fusión

¿Cómo combinar señales heterogéneas?

03

Aumento

¿Cómo estructurar y enriquecer el prompt?

04

Generación

¿Cómo inferir respuestas ancladas en evidencia?

Idea central: El rendimiento final depende de que la evidencia recuperada sea relevante y correlacionable entre modalidades.

Marco Teórico

¿Qué investiga la literatura?

Taxonomía resumida a partir del survey de Abootorabi et al. (2025).

RETRIEVAL

Búsqueda: índices densos eficientes

Encoders: modelos multimodales

Re-ranking: refinamiento Top-K

FUSION

Score fusion: combinación lineal

Atención: cross & co-attention

Proyección: CLIP embeddings

AUGMENT

Contexto: selección adaptativa

Iterativo: re-consulta dinámica

Poda: reducción de ruido

GENERATION

Razonamiento: CoT multimodal

Atribución: citas de fuentes

Agentes: coordinación activa

ROBUSTNESS

Alineación: contrastive losses

Resiliencia: tolerancia al ruido

Conflicto: resolución cruzada

Marco Teórico

Recuperación cross-modal

Una consulta de texto recupera evidencia visual mediante representaciones compartidas.



MODELOS CLAVE: **CLIP / BLIP:** Proyectan modalidades heterogéneas a espacios semánticamente comparables.

Marco Teórico

Recuperar no es lo mismo que fusionar

La evidencia puede ser relevante de forma aislada y aun así difícil de articular.

ENFOQUE 01

Score Fusion

Ponderación lineal de señales de relevancia entre modalidades independientes.

ENFOQUE 02

Cross-Attention

Mecanismos de atención mutua para ponderar interacciones densas token-parche.

ENFOQUE 03

Espacio Unificado

Embeddings proyectados que consolidan la evidencia en una sola representación.

Reto Fundamental: Correspondencias indirectas, ruido perceptual y contradicción de evidencia inter-modal.

Marco Teórico

Aumento y generación

Estructuración contextual y razonamiento guiado con evidencia multicanal.

ETAPA 1

Evidencia

Top-K texto, gráficos, tablas e imágenes indexadas.

ETAPA 2

Contexto

Poda selectiva, aumento adaptativo o iterativo.

ETAPA 3

Razonamiento

In-context learning, CoT y afinamiento instruccional.

ETAPA 4

Respuesta

Generación fundamentada con citas verificables.

Dirección Emergente: Arquitecturas agénticas que coordinan recuperación, verificación cruzada y síntesis activa.

El Problema Abierto

Alineación cross-modal

El reto no radica en ingerir más modalidades, sino en correlacionarlas con fidelidad.

Pregunta / Texto ⇄ Imagen / Gráfico

¿Representan la misma entidad? ¿Soportan la misma evidencia?

- **Espacios divergentes:** Encoders entrenados con objetivos y topologías dispares.
- **Granularidad dispar:** Un texto puntual frente a un gráfico con múltiples ejes y series.
- **Ruido contradictorio:** Metadatos o visuales que diluyen la evidencia exacta.

Marco Teórico

¿Cómo se evalúa un RAG multimodal?

La evaluación rigurosa desacopla la recuperación de la respuesta generativa.

CAPA 1

Retrieval

Recall@K • MRR

¿Apareció la evidencia correcta en Top-K? ¿En qué ranking relativo?

CAPA 2

Generation

Accuracy • BLEU/ROUGE

¿La respuesta final coincide semánticamente con la verdad fundamental?

CAPA 3

Eficiencia & Robustez

Latencia • Costo • Factualidad

¿El costo computacional y temporal justifica el despliegue en producción?

Problema metodológico: Protocolos heterogéneos en la literatura limitan comparaciones directas justas.

Transición Empírica

De la teoría al experimento

Evaluación de la recuperación cross-modal sobre preguntas analíticas de gráficos.

Pregunta de Investigación

¿En qué medida la evidencia visual mediante recuperación cross-modal supera a un baseline textual estructurado en ChartQA?

H1 • HIPÓTESIS ALTERNATIVA

La evidencia visual directa incrementará significativamente el Recall y la exactitud de respuesta.

H0 • HIPÓTESIS NULA

La incorporación de evidencia visual no generará una mejora sistemática frente al baseline textual.

Experimento

Diseño experimental controlado

Aislamiento estricto: misma consulta, generador idéntico (Gemini 2.5 Flash) y K=5.

RAMA A • TEXT-ONLY — BASELINE

Retriever
BM25 sobre tablas textuales

Generador
Gemini 3.8 Flash (Top-5 tablas)

RAMA B • MULTIMODAL — PROPUESTO

Retriever
CLIP ViT-B/32 sobre imágenes

Generador
Gemini 3.8 Flash (Top-5 imágenes)

Control experimental: Corpus idéntico (ChartQA), 60 consultas idénticas, K=5, criterio de parada y normalización idénticos.

Experimento

Datos y protocolo de evaluación

Muestra reproducible de ChartQA bajo configuración determinista controlada.

DATASET

ChartQA Val

60 preguntas analíticas. Corpus acotado a 1.000 gráficos. Seed = 42.

RETRIEVAL

Recall & MRR

Medición de acierto en Top-5 y posición en el ranking recíproco.

GENERACIÓN

Accuracy

Normalización estricta de respuestas numéricas y textuales.

INFERENCIA

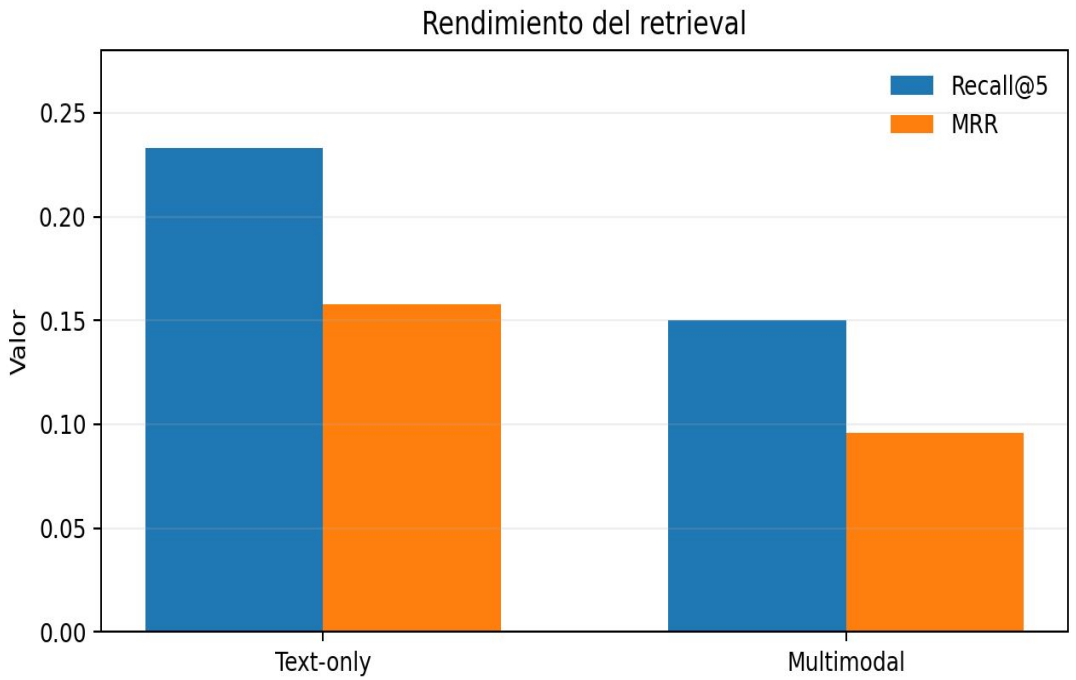
McNemar

Test exacto sobre casos discordantes para significancia estadística.

Resultados Empíricos

Resultados: recuperación de evidencia

El baseline textual superó contundentemente a CLIP en la captura de evidencia relevante.



MÉTRICA • RECALL@5

23.3%
Text-only (BM25)

15.0%
Multimodal (CLIP)

Diferencia neta: **-8.3 pp** en favor del retrieval textual.

MÉTRICA • MRR

0.158
Text-only (BM25)

0.096
Multimodal (CLIP)

Ranking de evidencia un **39.2% inferior** con embeddings visuales.

Conclusión: Los embeddings genéricos de CLIP no capturan con suficiente precisión la semántica visual de gráficos especializados.

Resultados Empíricos

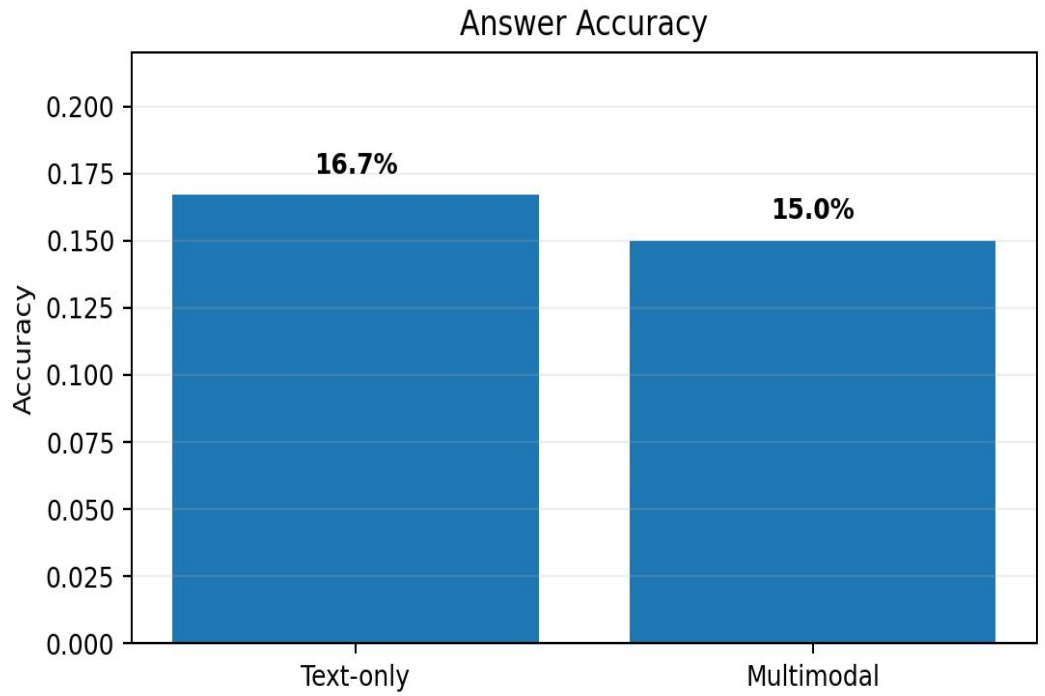
Resultados: generación y costo temporal

La diferencia en exactitud fue marginal; la penalización en latencia fue severa.

ANSWER ACCURACY

16.7% vs **15.0%**

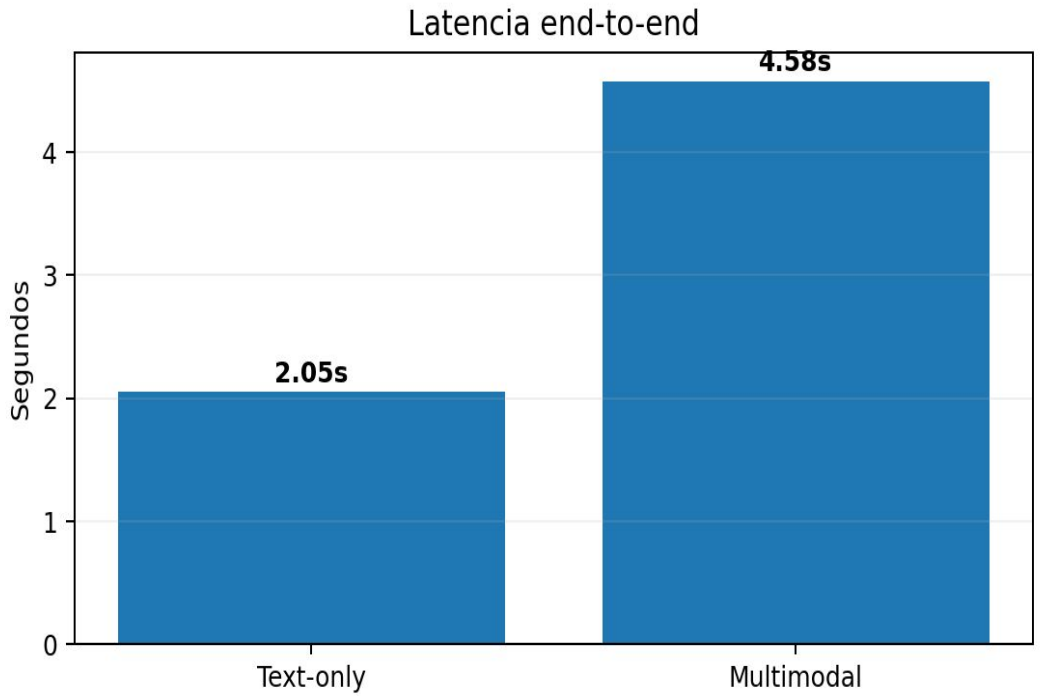
Text-only 16.7% vs Multimodal 15.0%. Variación estadísticamente indistinguible.



Resultados Empíricos

Resultados: generación y costo temporal

La diferencia en exactitud fue marginal; la penalización en latencia fue severa.



PENALIZACIÓN DE LATENCIA

2.24× más lento

2.05 s (Text-only) vs 4.58 s (Multimodal) por consulta procesada.

Resultados Empíricos

¿Dónde ayuda y dónde falla?

Distribución de aciertos sobre las 60 preguntas analizadas y prueba de significancia.

DESGLOSE CASO A CASO (N = 60)

3 Ambos correctos	6 MM mejora	7 MM empeora	44 Ambos fallan

TEST EXACTO DE MCNEMAR

Discordantes: 13 casos (6 vs 7)

$p = 1.000$

No hay significancia estadística: se acepta la hipótesis nula H0.

* Categorías exploratorias y heurísticas, no anotación oficial interna del benchmark ChartQA.

Discusión

Interpretación teórica de los hallazgos

El experimento no invalida el paradigma multimodal: evidencia el costo de una alineación defectuosa.

01

Más no es mejor

Añadir canales perceptuales sin alineación fina incrementa la entropía sin aportar evidencia útil.

02

Retrieval es el cuello

Si el contexto relevante no figura en Top-K, ningún generador multimodal puede salvar la respuesta.

03

Consistencia teórica

Los resultados ratifican los surveys recientes: la brecha de granularidad entre texto y visual persiste.

Conclusión del caso: Text-only superó en recuperación, obtuvo precisión ligeramente mayor y fue 2.24× más eficiente.

Discusión

Limitaciones y próximos pasos

Alcance circunscrito a este pipeline experimental, no a todo el campo del RAG multimodal.

LIMITACIONES DEL ESTUDIO

- Muestra acotada a 60 preguntas analíticas.
- Corpus restringido a 1.000 gráficos preseleccionados.
- CLIP como único encoder visual (sin tuning en charts).
- Sin exploración de esquemas híbridos de re-ranking.

LÍNEAS DE INVESTIGACIÓN FUTURA

- Encoders especializados en visualización de datos (MatCha, DePlot).
- Fusión explícita y re-ranking híbrido (BM25 + Dense).
- Recuperación activa guiada por agentes iterativos.
- Evaluación cruzada en InfoVQA y PlotQA.

CONCLUSIÓN

El valor del RAG multimodal no reside en añadir modalidades, sino en alinearlas con rigor.

En nuestro experimento sobre ChartQA, la recuperación visual con CLIP no superó al baseline textual estructurado.

La pregunta abierta persiste: ¿cómo recuperar, relacionar y fusionar evidencia heterogénea de forma robusta y eficiente?